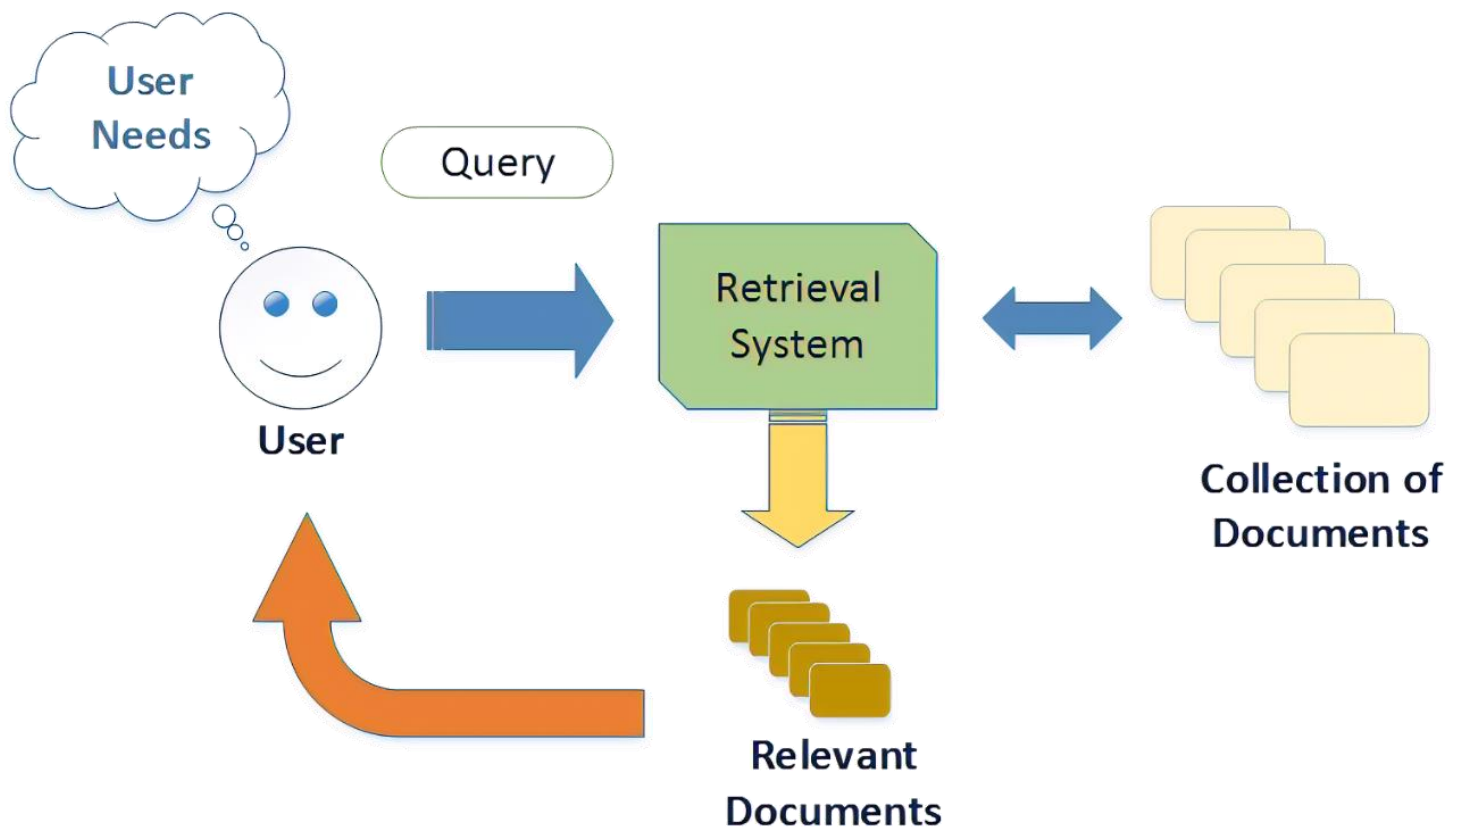


Ανάκτηση Πληροφορίας

Ονοματεπώνυμο : Καρρά Αντωνία

A.M. : 4075



Περιγραφή πρώτης φάσης

Τρόπος συλλογής των δεδομένων

Για την δημιουργία της συλλογής δεδομένων η οποία θα περιλαμβάνει πληροφορίες 500 ταινίες , συνέλεξα δεδομένα ταινιών κάνοντας scrapping από το IMDB και συγκεκριμένα από το παρακάτω link: [top 500 Greatest movies of all time - IMDb](#), με την χρήση του εργαλείου BeautifulSoup, μια βιβλιοθήκη της Python, η οποία σου επιτρέπει να εξάγεις δεδομένα από οποιαδήποτε ιστοσελίδα. Ακόμη έκανα import και την βιβλιοθήκη request, η οποία μας δίνει την δυνατότητα να πραγματοποιήσουμε HTML requests στην ιστοσελίδα που μας ενδιαφέρει με την εντολή, `page = requests.get(u)` όπου u, το URL της ιστοσελίδας.

Ύστερα, για την εξαγωγή των δεδομένων αναζήτησα τον HTML κώδικα της ιστοσελίδας και τα κατάλληλα elements των οποίων τα arguments θέλω να βρω. Τα arguments περιέχουν την πληροφορία που θα χρειαστώ για την δημιουργία του corpus.

Πιο συγκεκριμένα, τα arguments αυτά αποτελούν και τα πεδία της συλλογής των δεδομένων που θέλω να δημιουργήσω και τα οποία είναι τα ακόλουθα:

- Title
- Plot
- Year
- Genre
- Runtime
- Director
- Cast

Τα παραπάνω fields για την κάθε ταινία βρέθηκαν με την βοήθεια της συνάρτησης find() του BeautifulSoup, ψάχνοντας τα κατάλληλα elements και class που περιέχουν την πληροφορία που μας ενδιαφέρει. Για παράδειγμα η παρακάτω εντολή

```
runtime = film.find('span',class_='runtime').get_text().replace('\n','')
```

ψάχνει στον HTML κώδικα το element = 'span' με το όνομα της κλάσης class_='runtime' και

```
Title:Pulp Fiction
runtime:154 min
Title:Casablanca
runtime:102 min
Title:The third man
runtime:104 min
Title:Star Wars: Episode 5 - The Empire Counterattack
runtime:124 min
Title:Schindler's List
runtime:195 min
Title:Revelation now!
runtime:147 min
Title:The good guys
runtime:145 min
Title:Singing in the rain
runtime:103 min
```

το οποίο μας εμφανίζει την διάρκεια όλων των ταινιών που έχουμε στην συλλογή μας. Με ανάλογο τρόπο βρίσκουμε και τα υπόλοιπα πεδία. Το συγκεκριμένο παράδειγμα μας τυπώνει

Αφού λοιπόν εξήγαμε τα δεδομένα πρέπει να δημιουργήσουμε ένα csv αρχείο, στο οποίο θα αποθηκεύουμε τα πεδία και τις τιμές τους. Αυτό θα πραγματοποιηθεί με την βοήθεια της βιβλιοθήκης pandas, όπου και θα δημιουργήσουμε ένα dataframe που θα το μετατρέψουμε σε ένα csv αρχείο. Αυτό επιτυγχάνεται με τις ακόλουθες γραμμές κώδικα:

```
df = pd.DataFrame(fields_film, columns = ['Title', 'Year', 'Plot', 'Rintime', 'Genre', 'Imdb rating'])
df.to_csv('films DataBase.csv')
```

Και μας τυπώνει:

```
C:\Users\tania\Desktop\University\Epiloghs\Information_Retrieval>python scrape.py
```

	Title	Year	...	Genre	Imdb rating
0	Citizen Kane	(1941)	...	Drama, Mystery	8.3
1	The Godfather	(1972)	...	Crime, Drama	9.2
2	The Wizard of Oz	(1939)	...	Adventure, Family, Fantasy	8.1
3	Last release: Rita Hayworth	(1994)	...	Drama	9.3
4	Pulp Fiction	(1994)	...	Crime, Drama	8.9
..
95	Los Angeles: Confidential	(1997)	...	Crime, Drama, Mystery	8.3
96	Mad Max: The Road to Rage	(2015)	...	Action, Adventure, Sci-Fi	8.1
97	Pinocchio	(1940)	...	Animation, Adventure, Comedy	7.5
98	The 39 stairs	(1935)	...	Crime, Mystery, Thriller	7.6
99	Rome, Fortified City	(1945)	...	Drama, Thriller, War	8

```
[100 rows x 6 columns]
```

Στυγμιότυπο από το csv αρχείο

[illegible]

Περιγραφή του σχεδιασμού του συστήματος

Αρχικά ο στόχος του συστήματος που πρόκειται να σχεδιάσουμε είναι η ανάκτηση της πληροφορίας, η οποία θα είναι και η απάντηση στο ερώτημα κάποιου χρήστη. Με τον όρο ανάκτηση πληροφορίας εννοούμε την ανάκτηση εγγράφων που περιέχουν πληροφορία, η οποία χρειάζεται να είναι όσο πιο συναφής δύναται με την ανάγκη πληροφόρησης του χρήστη, ώστε να ολοκληρωθεί το ερώτημα του.

Πιο συγκεκριμένα, εδώ κάνει την εμφάνιση της η Lucene μια open-source βιβλιοθήκη λογισμικού υλοποιημένη σε Java. Η Lucene σου επιτρέπει να προσθέσεις δυνατότητες αναζήτησης σε μια εφαρμογή, καθώς μπορεί να ευρετηριοποιήσει και να κάνει αναζητά οποιασδήποτε μορφής δεδομένα, από τα οποία εξάγεις από κάποιο text. Είναι ένα χρήσιμο εργαλείο, αφού δεν την ενδιαφέρει η πηγή των δεδομένων, το format τους ή ακόμα και η γλώσσα τους, αρκεί να μπορεί να εξάγει κάποιο κείμενο από εκεί.

- **Indexing :** Η διαδικασία του indexing θα μας βοηθήσει να διαχειριστούμε μεγάλο αριθμό αρχείων και μεγάλα σε μέγεθος πιο γρηγορά από το αν γινόταν σειριακά η διαδικασία αναζήτησης της πληροφορίας. Το αποτέλεσμα αυτής της διαδικασίας ονομάζεται index, μια ειδικά διαμορφωμένη δομή δεδομένων αποθηκευμένη στο file system ως μια ομάδα από index files . Το indexing ακολουθεί τα παρακάτω βήματα.

- 1) **Aquire content:** Η Lucene δεν παρέχει κάποια λειτουργική υποστήριξη στο συγκεκριμένο βήμα. Αντίθετα, υποστηρίζεται εξ' ολοκλήρου από την εφαρμογή ή από ξεχωριστά τμήματα του λογισμικού. Υπάρχουν ορισμένοι open source crawlers που μπορούν να φανούν χρήσιμοι στην υλοποίηση του βήματος αυτού, όπως Solr, Nutch, OpenNLP κλπ.
- 2) **Build Document:** Μετάφραση του content σε units/documents. Το κάθε document αποτελείται από διάφορα, ξεχωριστά fields(πεδία) που περιέχουν κάποια τιμή. Τα fields μπορούν να καταταχθούν σε δυο κατηγορίες με την πρώτη να είναι (είτε) indexes (είτε όχι). Σε αυτή την περίπτωση οι τιμές του δεν αναλύονται από τον Analyzer. Στην δική μας περίπτωση, σε αυτή την κατηγορία θα ανήκουν το title, year, runtime, duration (cast, director?). Η δεύτερη κατηγορία περιέχει fields τα οποία θεωρούνται είτε stored είτε όχι και αυτά είναι τα πεδία που πρέπει να εμφανίζονται στον χρήστη αναλυτικά. (plot, director). Επομένως θα δημιουργήσουμε μια μέθοδο η οποία θα δημιουργεί document και θα προσθέτει σε αυτό τα καινούρια fields.

```

private Document getDocument (File file) throws IOException{
    Document doc = new Document();

    //create the fields, set field to be analyzed or not and add them to the
    document

    doc.add(new TextField('title', title, Field.Store.YES, Field.Index.ANALYZED));
    doc.add(new TextField('plot', plot, Field.Store.YES));
    doc.add(new StringField('year', year, Field.Index.NOT_ANALYZED)); ?
    doc.add(new StringField('runtime', runtime, Field.Index.NOT_ANALYZED));?
    doc.add(new StringField('plot', plot, Field.Index.NOT_ANALYZED));?

    return doc;
}

```

- 3) **Analyze Document and Index Document:** Η ευρετηριοποίηση ενός document δεν γίνεται αμέσως. Χρειάζεται πρώτα η διάσπαση του text σε μια σειρά από ανεξάρτητα μέρη, τα tokens. Το βήμα αυτό αποφασίζει πως θα χωριστούν τα textual fields σε ακολουθία από tokens. Και τώρα τίθενται τα εξής ερωτήματα: Πως θα χειριστούμε τις σύνθετες λέξεις; Θα χρειαστεί να εισάγουμε και τις συνώνυμες τους; κλπ.

Τέλος θα δημιουργούμε έναν IndexWriter στον οποίο θα προσθέτουμε τα documents με την μέθοδο **addDocument()**
 Σημείωση: θα χρησιμοποιήσουμε τον **StopAnalyzer()**, ο οποίος αφαιρεί τις stop words από το token list που θα έχουμε ήδη δημιουργήσει(**StopFilter**), καθώς επίσης κάνει split το κείμενο με βάση τους non-letter χαρακτήρες(**LetterTokenizer**)

Private IndexWriter w;

w = new IndexWriter(indexDir,new StopAnalyzer(),...)

•
•
•

private void indexFile(File file) throws IOEXCEPTION{

Document document = getDocument(file);

w.addDocument(doc) //add the new document in the index

- **Components of searching:** **Searching** ονομάζεται η διαδικασία η οποία αναζητά μια λέξη μέσα στο ευρετήριο(index) και προσπαθεί να βρει τα documents που εμφανίζουν την συγκεκριμένη λέξη και αποτελείται από τα παρακάτω στοιχεία.

- 1) **Search User Interface:** Το user interface είναι στην ουσία αυτό που βλέπει ο χρήστης στον web browser για παράδειγμα, όταν έρχεται σε επαφή με την μηχανή αναζήτησης. Είναι απαραίτητο να διατηρήσουμε την δομή του όσο πιο απλή γίνεται, το οποίο πρέπει να είναι πάντα ορατός τον χρήστη. Ακόμη η παρουσίαση των αποτελεσμάτων είναι πολύ σημαντική, όπως το να εμφανίζονται σε έντονη γραμματοσειρά οι επεξηγήσεις που αναφέρονται σε κάποια αστοχία σε σχέση με την αναζήτηση.
- 2) **Build Query:** Αφού ο χρήστης υποβάλλει την αίτηση αναζήτησης, συχνά ως αποτέλεσμα σε HTML μορφή ή ως Ajax αίτημα, υποβάλλεται από τον browser στον server μας. Γι' αυτό τον λόγο πρέπει να μεταφράσουμε το αίτημα σε ένα Query αντικείμενο της μηχανής αναζήτησης. Η Lucene παρέχει ένα εργαλείο, το οποίο ονομάζεται QueryParser

QueryParser parser = new QueryParser (Version matchVersion,

String field,

Analyzer analyzer);

Η παράμετρος **field** είναι στην ουσία ένα default field που εκπροσωπεί όλους τους όρους που θα αναζητήσει ο χρήστης, εκτός και αν η αναζήτηση γίνει με την μορφή **field:text**. Έπειτα η Query Parser οντότητα έχει μια parse() μέθοδο, την

public Query parse (String query) throws ParseException;

Αν η αποτύχει η ανάλυση της έκφρασης εμφανίζεται ένα **ParseException**, το οποίο ουσιαστικά είναι ένα μήνυμα που εξηγεί τον λόγο που απέτυχε η ανάλυση. Ύστερα από την διαδικασία του **QueryParser**, τα αποτελέσματα περιέχονται στην δομή **Query**, τα οποία ταξινομούνται με την σειρά που αιτήθηκαν

- 3) **IndexSearcher:** Αρχικά δημιουργούμε μια οντότητα IndexSearcher, η οποία ανοίγει το search index και στην συνέχεια με search μεθόδους παρουσιάζει τα αποτελέσματα της αναζήτησης. Τότε αυτό που επιστρέφεται είναι μια κλάση TopDocs που παρουσιάζει τα καλύτερα matches και το χρησιμοποιούμε για να παρουσιάσουμε τα αποτελέσματα στον χρήστη. Αφού καθορίσουμε το directory και αφού δημιουργήσουμε ένα αντικείμενο reader τύπου IndexReader, επιτέλους έρχεται και η σειρά της δημιουργία του IndexSearcher με την εντολή *IndexSearcher searcher = new IndexSearcher(reader);*

- 4) **TopDocs**: Όπως αναφέραμε και παραπάνω είναι μια κλάση που επιστρέφει τα μέγιστα hits. Το attribute **TopDocs.totalHit** επιστρέφει τον αριθμό των documents που έγιναν ταίριαξαν με την αναζήτηση του χρήστη ταξινομημένα σε φθίνουσα σειρά.
- 5) **ScoreDocs**: Το **TopDocs.scoreDocs** είναι ένας πίνακας που περιλαμβάνει τον απαιτούμενο αριθμό των καλύτερων matches. Κάθε **ScoreDocs** οντότητα διατηρεί ένα float score και ένα int doc, το ID του document, οποίο μπορεί να χρησιμοποιηθεί για την ανάκτηση των αποθηκευμένων πεδίων του συγκεκριμένου document καλώντας **IndexSearcher.document(doc)**. Τέλος, αν καλέσουμε **TopDocs.getMaxScore()**, θα μας επιστραφεί το καλύτερο score απ' όλα τα matches.

